

# Aprendizaje profundo

## REDES CONVOLUCIONALES

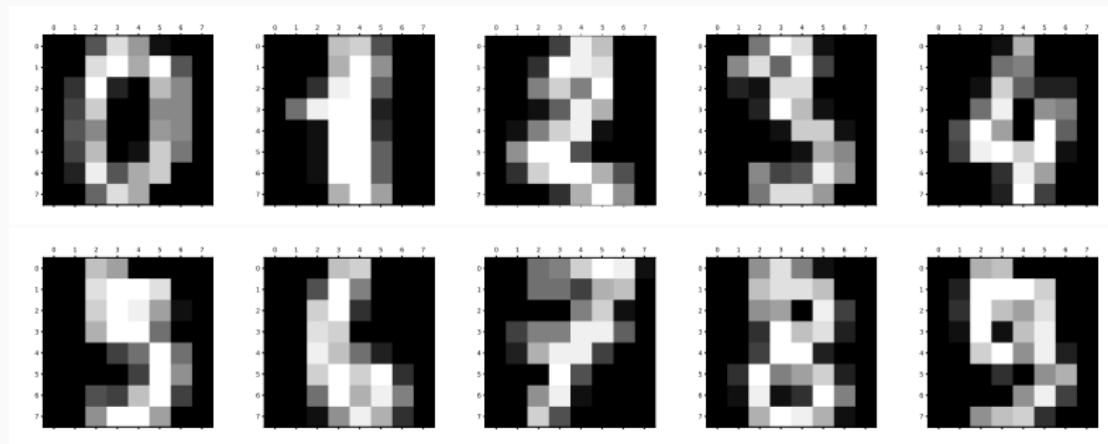
---

Gibran Fuentes-Pineda

Septiembre 2021

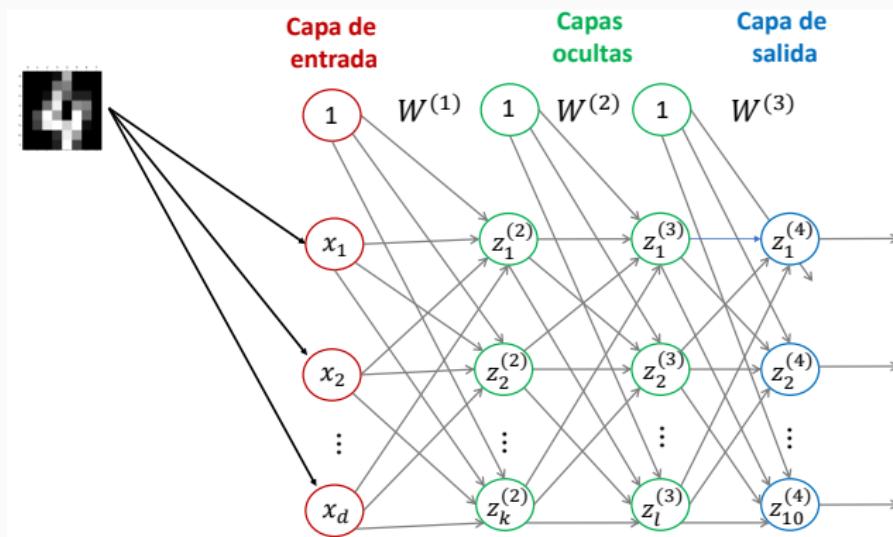
# Clasificación de imágenes

- Por ejemplo, clasificar dígitos escritos a mano



# Clasificación de imágenes con PMC

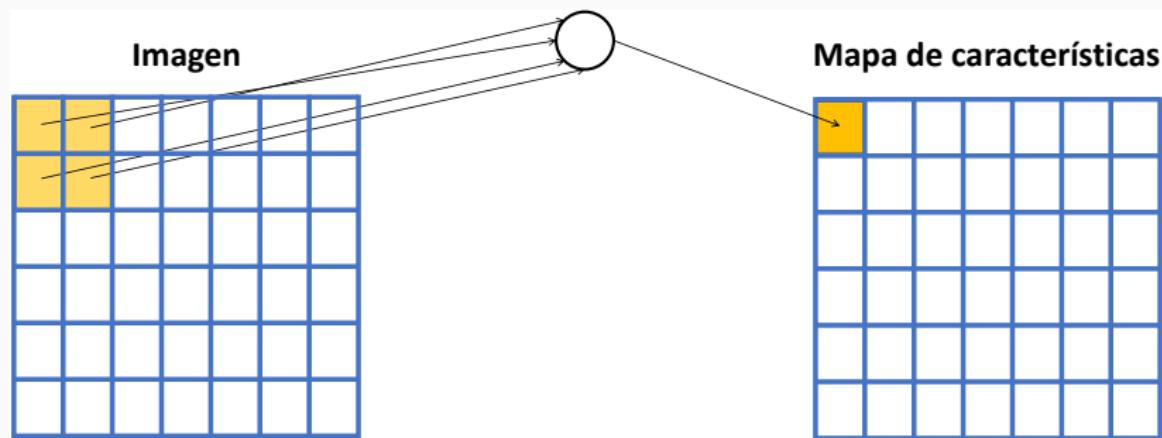
- Redes perceptrón multicapa tienen muchos parámetros
  - Por ej., si tenemos imágenes de  $32 \times 32$  y 1 red con 1 sola capa oculta con 10 neuronas tendríamos  $(32 \times 32 \times 10) + 1$  pesos



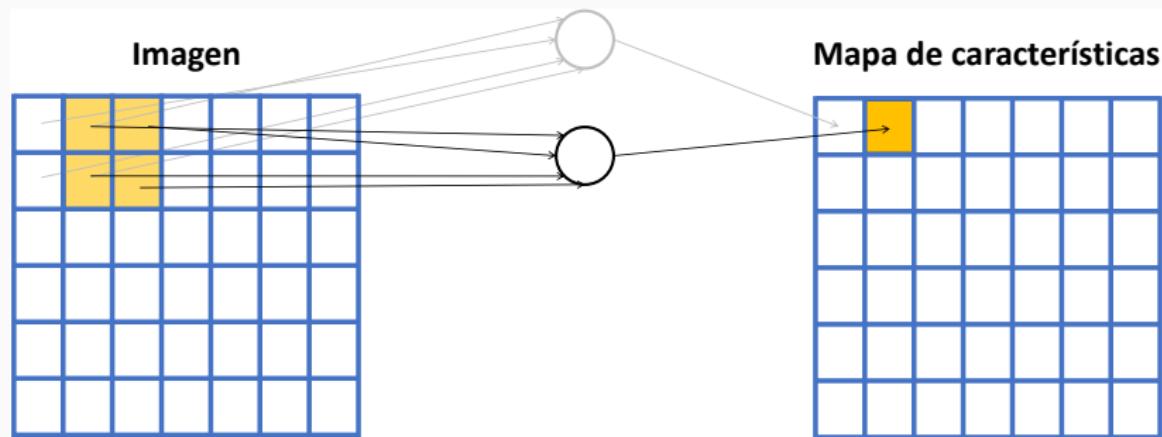
# Capa convolucional

- Pueden verse como un caso especial de una capa densa con 2 variaciones
  1. Conectividad local (dispersa)
  2. Pesos compartidos
- Las representaciones obtenidas son más eficientes
- La operación es equivariante

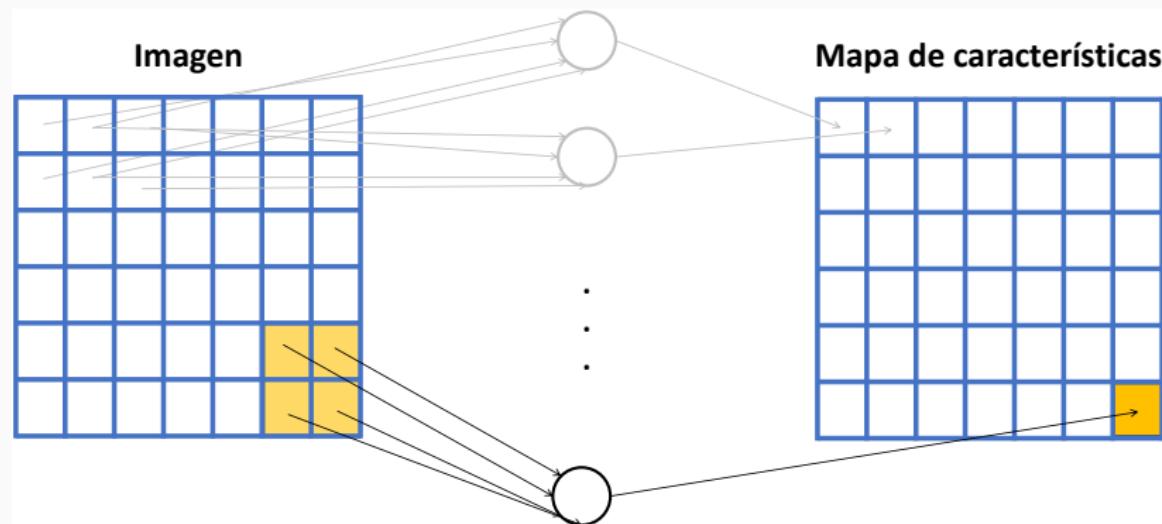
## Conectividad local (1)



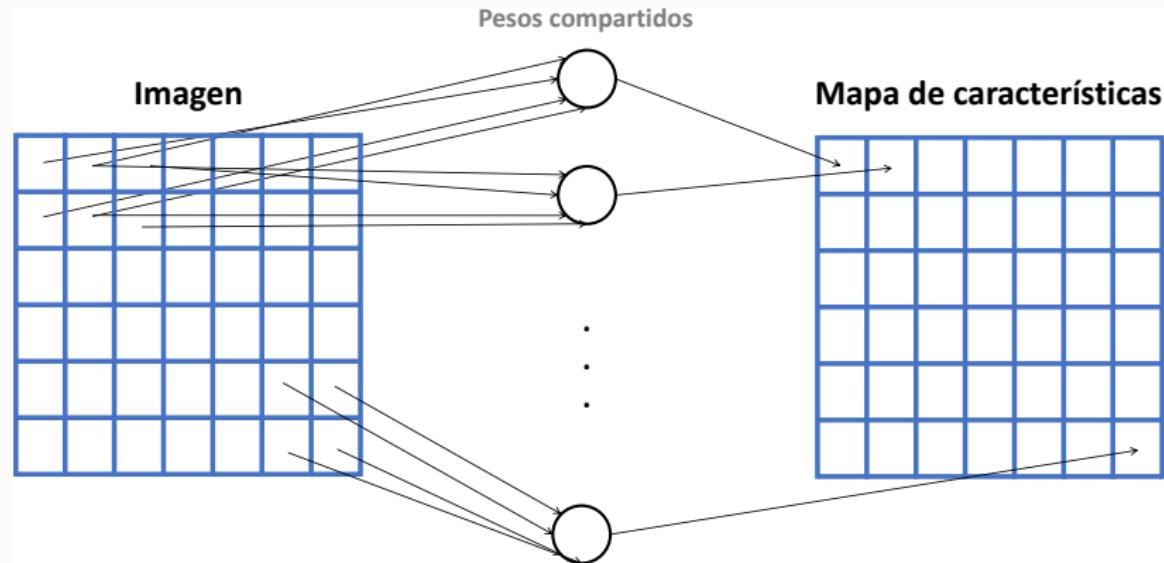
## Conectividad local (2)



## Conectividad local (3)



# Pesos compartidos



# Operación de convolución

- Convolución en 1 dimensión
  - Continua  $s(t) = (x * k)(t) = \int_m x(m)k(t - m)dm$
  - Discreta  $s[i] = (x * k)[i] = \sum_{m=-\infty}^{\infty} x[m]k[i - m]$
- Convolución en 2 dimensiones (discreta)
  - $S[i, j] = (I * K)[i, j] = \sum_m \sum_n I[m, n]K[i - m, j - n]$
  - $S[i, j] = (K * I)[i, j] = \sum_m \sum_n I[i - m, j - n]K[m, n]$
- Correlación cruzada (discreta)
  - $S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n)K(m, n)$

# Operación de convolución

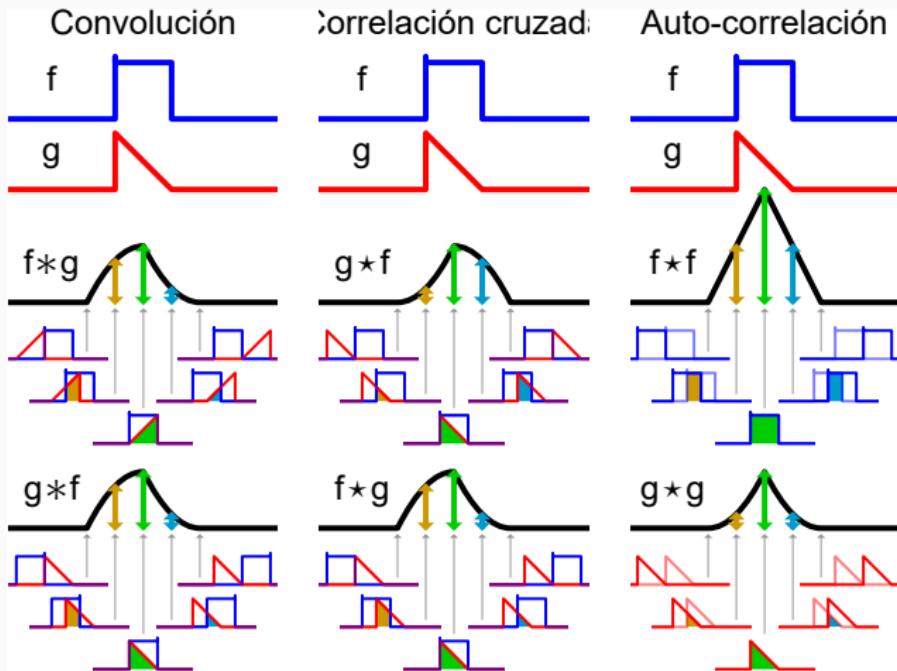


Imagen tomada de Wikipedia (Convolution)

# Convolución de una imagen con un filtro (1)

The diagram illustrates the convolution process between an input image  $I$  and a kernel  $K$ .

**Input Image ( $I$ ):**

0	1	1	1	0	0	0
0	0	1	1	1	0	0
0	0	0	1	1	1	0
0	0	0	1	1	0	0
0	0	1	1	0	0	0
0	1	1	0	0	0	0
1	1	0	0	0	0	0

**Kernel ( $K$ ):**

1	0	1
0	1	0
1	0	1

**Result ( $I * K$ ):**

1	4	3	4	1
1	2	4	3	3
1	2	3	4	1
1	3	3	1	1
3	3	1	1	0

## Convolución de una imagen con un filtro (2)

The diagram illustrates the convolution process between an input image  $I$  and a kernel  $K$ .

**Input Image ( $I$ ):**

0	1	1	1	0	0	0
0	0	1	1	1	0	0
0	0	0	1	1	1	0
0	0	0	1	1	1	0
0	0	1	1	0	0	0
0	1	1	0	0	0	0
1	1	0	0	0	0	0

**Kernel ( $K$ ):**

1	0	1
0	1	0
1	0	1

**Result of Convolution ( $I * K$ ):**

1	4	3	4	1
1	2	4	3	3
1	2	3	4	1
1	3	3	1	1
3	3	1	1	0

The convolution operation involves sliding the kernel over the input image and performing element-wise multiplication (indicated by blue dotted lines) followed by summation (indicated by green dotted lines) to produce the result.

## Convolución de una imagen con un filtro (3)

$$\begin{array}{|c|c|c|c|c|} \hline 0 & 1 & 1 & 1 & 0 \\ \hline 0 & 0 & 1 & 1 & 1 \\ \hline 0 & 0 & 0 & 1 & 1 \\ \hline 0 & 0 & 0 & 1 & 1 \\ \hline 0 & 0 & 1 & 1 & 0 \\ \hline 0 & 1 & 1 & 0 & 0 \\ \hline 1 & 1 & 0 & 0 & 0 \\ \hline \end{array} \quad \begin{array}{|c|c|c|} \hline 1 & 0 & 1 \\ \hline 0 & 1 & 0 \\ \hline 1 & 0 & 1 \\ \hline \end{array} \quad = \quad \begin{array}{|c|c|c|c|c|} \hline 1 & 4 & 3 & 4 & 1 \\ \hline 1 & 2 & 4 & 3 & 3 \\ \hline 1 & 2 & 3 & 4 & 1 \\ \hline 1 & 3 & 3 & 1 & 1 \\ \hline 3 & 3 & 1 & 1 & 0 \\ \hline \end{array}$$

The diagram illustrates the convolution process between an input image  $I$  and a kernel  $K$ . The input image  $I$  is a 7x5 grid of values. A 3x3 kernel  $K$  is applied to it. The result of the convolution is shown in the output matrix  $I * K$ , where each value is the result of the element-wise multiplication (highlighted with dashed lines) and summation of the kernel's elements with the corresponding input values. The result is a 5x3 matrix.

## Convolución de una imagen con un filtro (4)

$$\begin{array}{|c|c|c|c|c|c|c|c|} \hline 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ \hline 0 & 0 & 1 & 1 & 1 & 0 & 0 \\ \hline 0 & 0 & 0 & 1 & 1 & 1 & 0 \\ \hline \textcolor{red}{0} & \textcolor{red}{0} & \textcolor{red}{0} & \textcolor{red}{1} & 1 & 1 & 0 \\ \hline \textcolor{red}{0} & \textcolor{red}{0} & \textcolor{red}{0} & \textcolor{red}{\times 1} & 1 & 1 & 0 \\ \hline \textcolor{red}{0} & \textcolor{red}{0} & \textcolor{red}{1} & 1 & 1 & 0 & 0 \\ \hline \textcolor{red}{0} & \textcolor{red}{\times 0} & \textcolor{red}{\times 0} & \textcolor{red}{1} & 1 & 0 & 0 \\ \hline 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ \hline \end{array} \quad * \quad \begin{array}{|c|c|c|} \hline 1 & 0 & 1 \\ \hline 0 & 1 & 0 \\ \hline 1 & 0 & 1 \\ \hline \end{array} \quad = \quad \begin{array}{|c|c|c|c|c|} \hline 1 & 4 & 3 & 4 & 1 \\ \hline 1 & 2 & 4 & 3 & 3 \\ \hline 1 & 2 & 3 & 4 & 1 \\ \hline \textcolor{green}{1} & \textcolor{green}{3} & \textcolor{green}{3} & \textcolor{green}{1} & \textcolor{green}{1} \\ \hline 3 & 3 & 1 & 1 & 0 \\ \hline \end{array}$$

The diagram illustrates the convolution process between a 7x7 input image  $I$  and a 3x3 kernel  $K$ . The input image  $I$  has values ranging from 0 to 1. The kernel  $K$  has values 1, 0, 1; 0, 1, 0; and 1, 0, 1. The result of the convolution,  $I * K$ , is shown in the bottom right. The result is highlighted with a green box around the value 1. Dotted lines connect the non-zero elements of the kernel to the corresponding elements in the input image, showing how they are multiplied and summed to produce the output value.

$\mathbf{K}$

$\mathbf{I} * \mathbf{K}$

# Capa convolucional

- Compuesta de filtros distintos
- La salida (mapas de activaciones) es un volumen

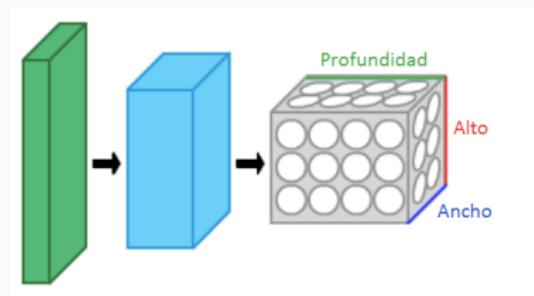
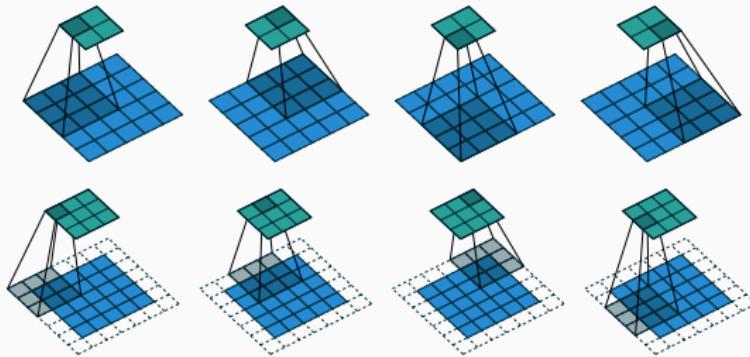


Imagen tomada de Wikipedia (Convolutional Neural Network)

# Capa convolucional: hiperparámetros

- Número de filtros  $N_{filtros}$ , tamaño de cada filtro  $F_H \times F_W$ , desplazamiento  $S$  (*stride*) y relleno (*padding*)



Imágenes creadas por Dumoulin and Visin. A guide to convolution arithmetic for deep learning, 2018.

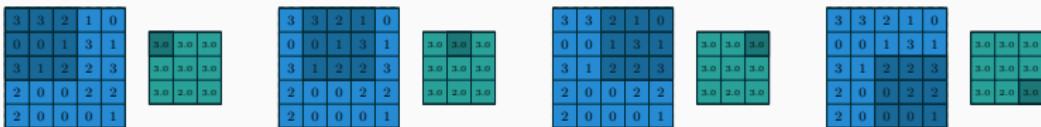
$$H^{\{\ell\}} = \frac{H^{\{\ell-1\}} + 2P^{\{\ell-1\}} - F_H^{\{\ell\}}}{S^{\{\ell\}}} + 1$$

$$W^{\{\ell\}} = \frac{W^{\{\ell-1\}} + 2P^{\{\ell-1\}} - F_W^{\{\ell\}}}{S^{\{\ell\}}} + 1$$

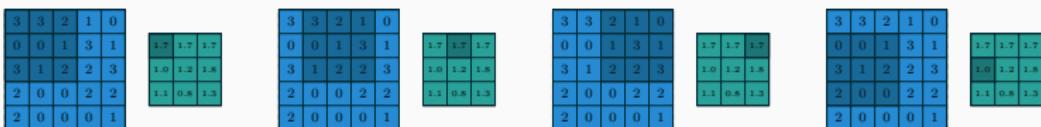
# Capa de submuestreo o decimación

- Capa para reducir dimensiones tomando el valor máximo (*max-pooling*) o el promedio (*average pooling*) de un grupo de activaciones usualmente contiguas

Máximo



Promedio



Imágenes creadas por Dumoulin and Visin. A guide to convolution arithmetic for deep learning, 2018.

## Capa de submuestreo: hiperparámetros

- Hiperparámetros: alto y ancho de la ventana que define el grupo ( $F_H, F_W$ ), desplazamiento  $S$ , relleno (*padding*)  $P$
- El alto  $H^{\{\ell\}}$  y ancho  $W^{\{\ell\}}$  de la salida de una capa de submuestreo está dado por

$$H^{\{\ell\}} = \frac{H^{\{\ell-1\}} + 2P - F_H}{S} + 1$$

$$W^{\{\ell\}} = \frac{W^{\{\ell-1\}} + 2P - F_W}{S} + 1$$

# Submuestro global promedio

- Reduce las dimensiones de un volumen de características, tomando únicamente el promedio de cada mapa

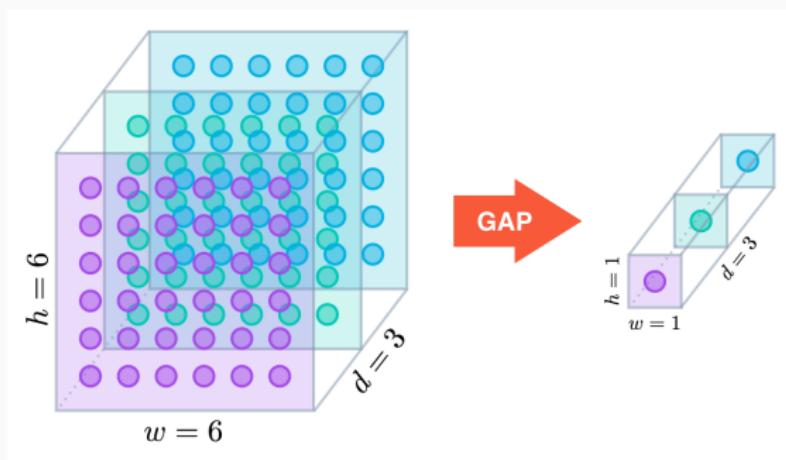


Imagen tomada de <https://alexisbcook.github.io/2017/global-average-pooling-layers-for-object-localization/>

- Hacia adelante
  - Se aplican las operaciones de convolución con correspondiente activación y decimación
- Hacia atrás
  - En la convolución cada neurona actualiza los gradientes por separado y al final se suman para actualizar los pesos compartidos
  - En la decimación se actualiza sólo la neurona ganadora (*max-pooling*)

# Convolución de $1 \times 1$

- Funciona como un tipo de decimación en profundidad

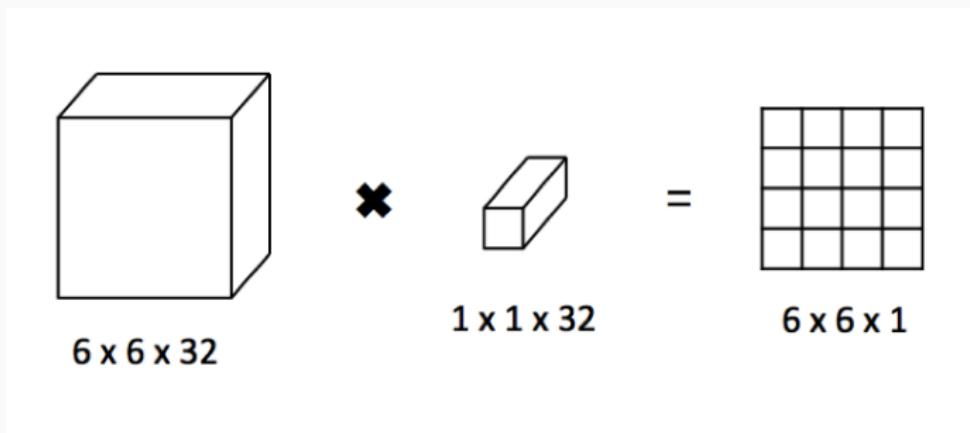


Imagen tomada de <https://medium.com/machine-learning-bites/deeplearning-series-convolutional-neural-networks-a9c2f2ee1524>

# Red neuronal convolucional

- Compuesta de dos bloques principales
  1. *Extracción de características*: múltiples capas convolucionales y de submuestreo
  2. *Clasificación*: Una o más capas completamente conectadas (incluyendo la capa de salida)

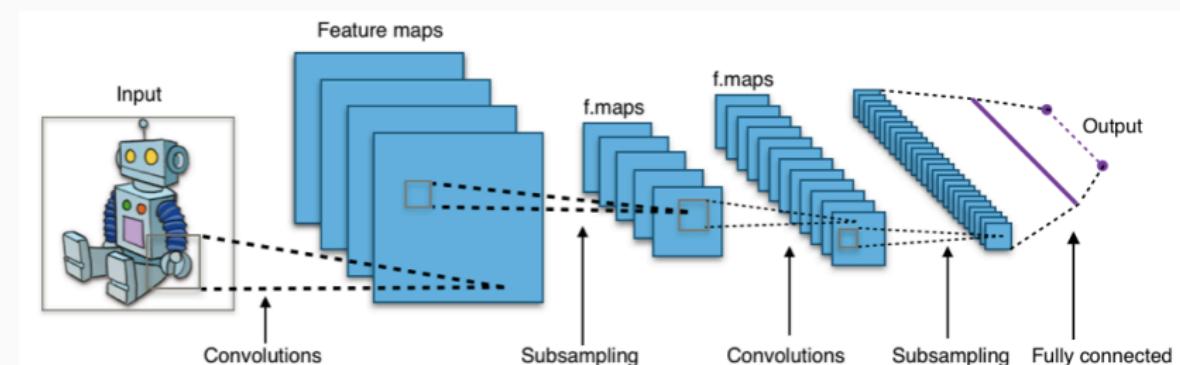


Imagen del usuario Aphex34 de Wikipedia. CC BY-SA 4.0

# Arquitecturas de redes convolucionales: LeNet

- Red poco profunda inspirada en la propuesta originalmente por LeCun et al. 1998

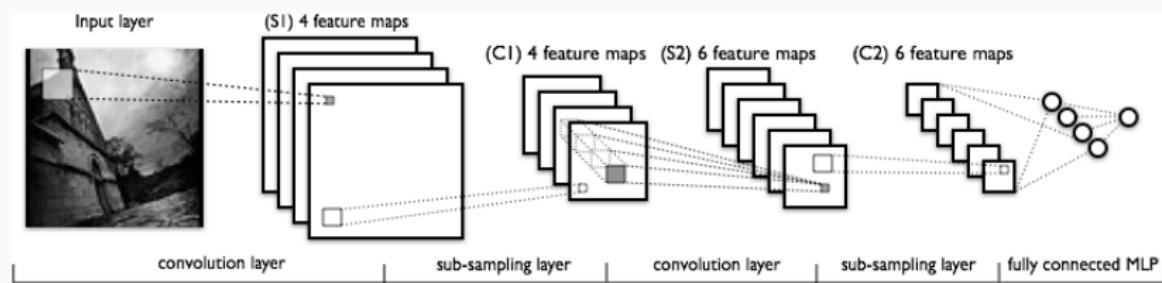


Imagen tomada de <http://deeplearning.net/tutorial/lenet.html>

# Arquitecturas de redes convolucionales: AlexNet

- Usa función de activación ReLU
- Entrenamiento con versión optimizada para 2 GPUs
- Normaliza respuestas
- Submuestreo con traslape

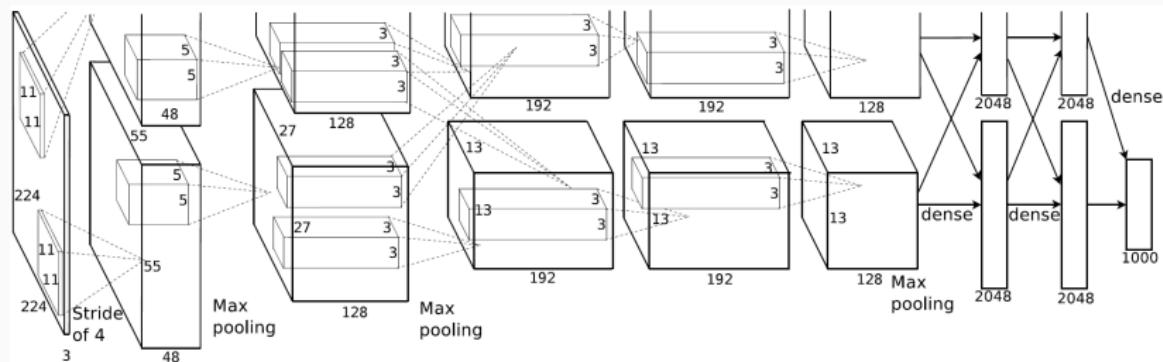


Imagen tomada de Krizhevsky et al. *ImageNet Classification with Deep Convolutional Neural Networks*, 2012

# Arquitecturas de redes convolucionales: ZFNet

- Muy similar a AlexNet pero usa filtros más pequeños con menor desplazamiento

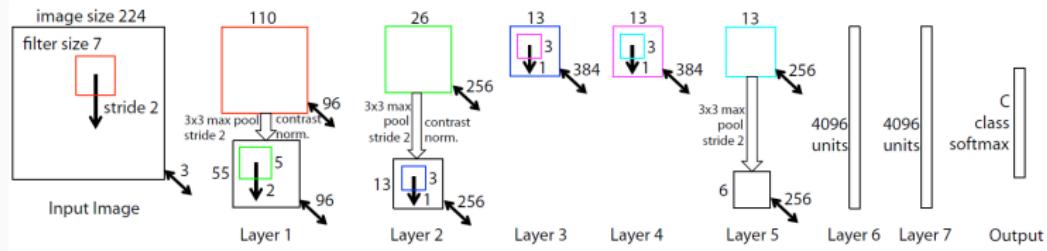


Imagen tomada de Zeiler and Fergus. *Visualizing and Understanding Convolutional Networks*, 2014

# Arquitecturas de redes convolucionales: VGGNet

- 19 capas
- Filtros de  $3 \times 3$  con desplazamientos de 1
- Max-pooling de  $2 \times 2$  con desplazamientos de 2



Imagen tomada de diapositivas de Simonyan (ILSVRC Workshop 2014)

# Arquitecturas de redes convolucionales: GoogleNet (1)

- 22 capas
- Utiliza bloques de capas convolucionales paralelas cuyas salidas se concatenan

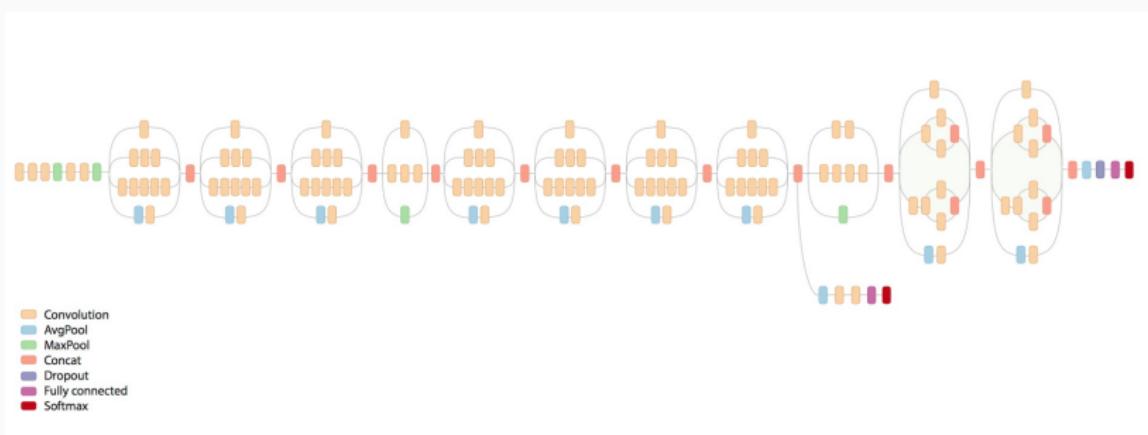


Imagen tomada de <https://research.googleblog.com/2016/03/train-your-own-image-classifier-with.html>

# Arquitecturas de redes convolucionales: GoogleNet (2)

type	patch size/ stride	output size	depth	#1×1	#3×3 reduce	#3×3	#5×5 reduce	#5×5	pool proj	params	ops
convolution	7×7/2	112×112×64	1							2.7K	34M
max pool	3×3/2	56×56×64	0								
convolution	3×3/1	56×56×192	2		64	192				112K	360M
max pool	3×3/2	28×28×192	0								
inception (3a)		28×28×256	2	64	96	128	16	32	32	159K	128M
inception (3b)		28×28×480	2	128	128	192	32	96	64	380K	304M
max pool	3×3/2	14×14×480	0								
inception (4a)		14×14×512	2	192	96	208	16	48	64	364K	73M
inception (4b)		14×14×512	2	160	112	224	24	64	64	437K	88M
inception (4c)		14×14×512	2	128	128	256	24	64	64	463K	100M
inception (4d)		14×14×528	2	112	144	288	32	64	64	580K	119M
inception (4e)		14×14×832	2	256	160	320	32	128	128	840K	170M
max pool	3×3/2	7×7×832	0								
inception (5a)		7×7×832	2	256	160	320	32	128	128	1072K	54M
inception (5b)		7×7×1024	2	384	192	384	48	128	128	1388K	71M
avg pool	7×7/1	1×1×1024	0								
dropout (40%)		1×1×1024	0								
linear		1×1×1000	1							1000K	1M
softmax		1×1×1000	0								

Tabla tomada de Szegedy et al. Going deeper with convolutions, 2014

# Bloques Inception

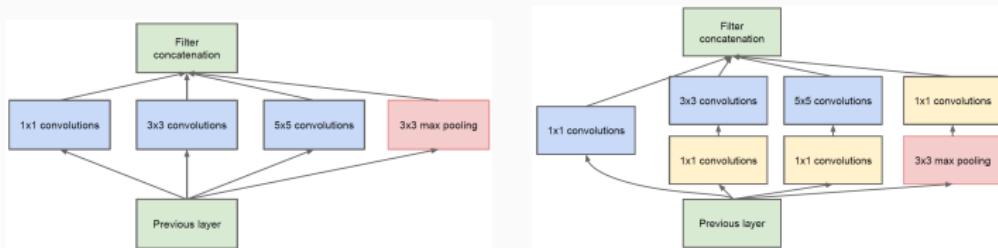


Imagen tomada de Szegedy et al. Going deeper with convolutions, 2014

# Sobre profundidad en redes convolucionales (1)

## Revolution of Depth

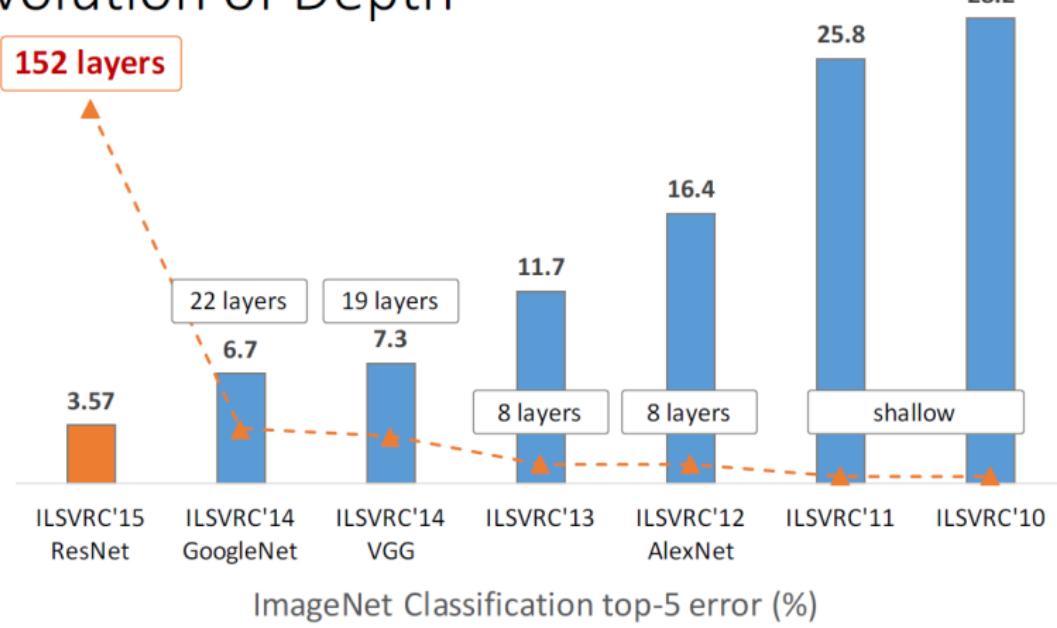


Imagen tomada de diapositivas de Kaiming He (ICML 2016)

## Sobre profundidad en redes convolucionales (2)

- Problemas con el desvanecimiento y explosión de respuestas (hacia adelante) y gradientes (hacia atrás)

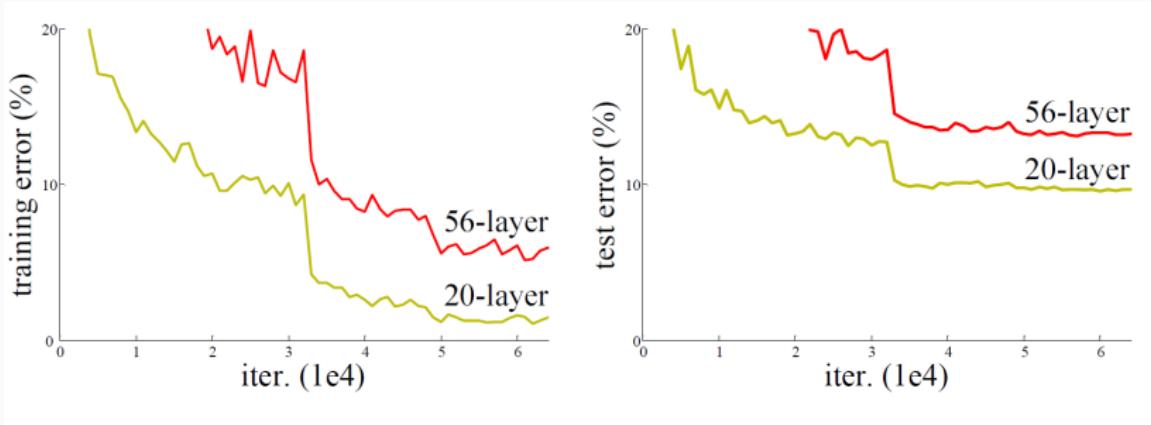


Imagen tomada de He et al. Deep Residual Learning for Image Recognition, 2015

# Entrenando redes más profundas: ResNet (1)

- Reformula los mapeos que se desean aprender a residuales
- Más fácil de optimizar los residuales que el mapeo original<sup>1</sup>

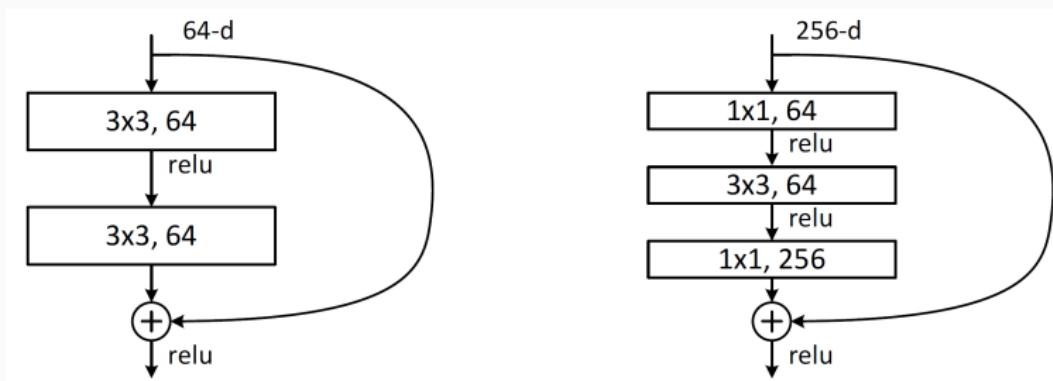


Imagen tomada de He et al. Deep Residual Learning for Image Recognition, 2015

<sup>1</sup>Se ha mostrado que son aproximadores universales: Lin y Jegelka. ResNet with one-neuron hidden layers is a Universal Approximator, 2018.

# Entrenando redes más profundas: ResNet (2)

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer	
conv1	112×112			7×7, 64, stride 2			
conv2_x	56×56			3×3 max pool, stride 2			
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$	
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$	
	1×1			average pool, 1000-d fc, softmax			
FLOPs		$1.8 \times 10^9$	$3.6 \times 10^9$	$3.8 \times 10^9$	$7.6 \times 10^9$	$11.3 \times 10^9$	

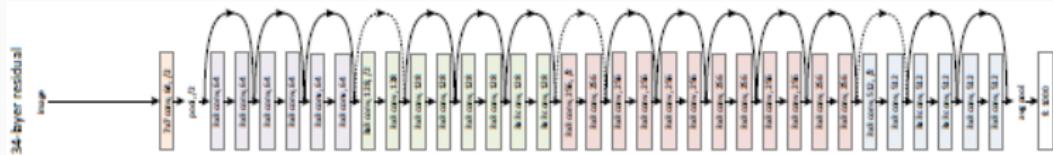


Imagen y tabla tomadas de He et al. Deep Residual Learning for Image Recognition, 2015

# Entrenando redes más profundas: ResNet (3)

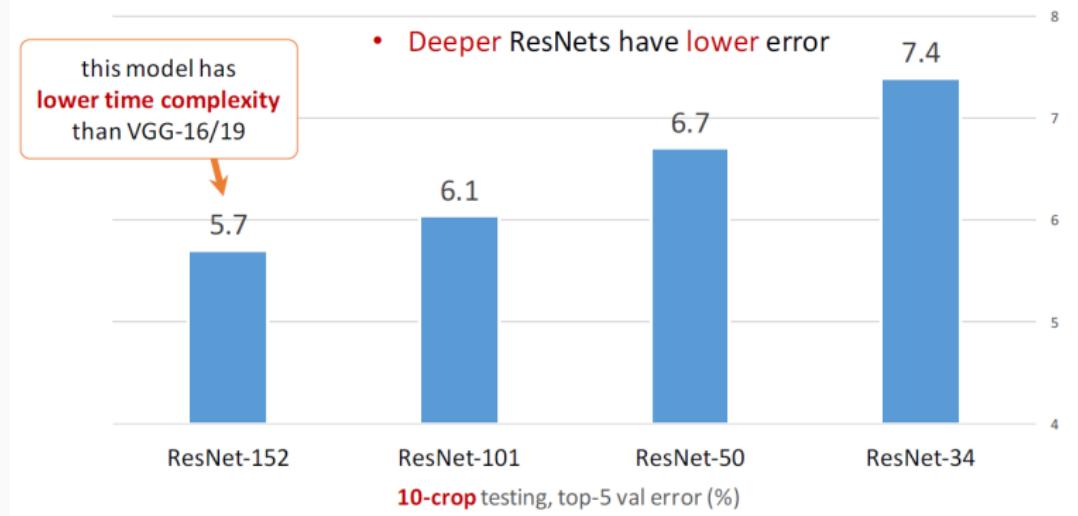


Imagen tomada de diapositivas de Kaiming He (ICML 2016)

# Entrenando redes más profundas: DenseNet (1)

- Utiliza bloques que conectan la salida de cada capa con las entradas de capas subsecuentes.

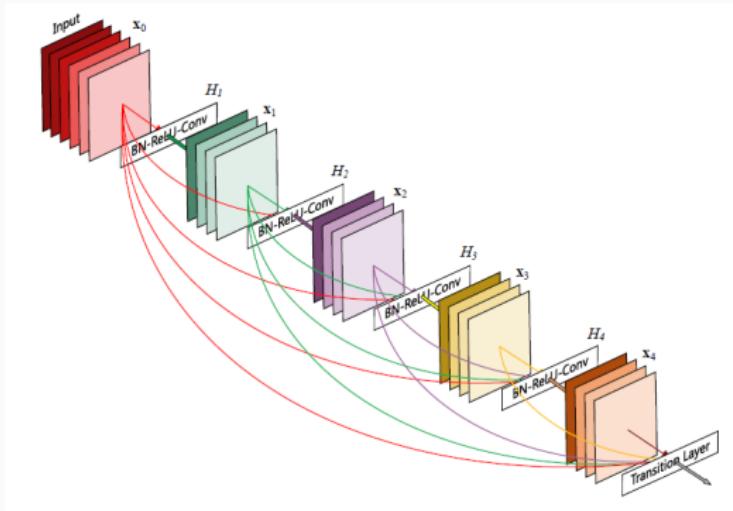


Imagen tomada de Huang et al. Densely Connected Convolutional Networks, 2018

# Entrenando redes más profundas: DenseNet (2)

Layers	Output Size	DenseNet-121( $k = 32$ )	DenseNet-169( $k = 32$ )	DenseNet-201( $k = 32$ )	DenseNet-161( $k = 48$ )
Convolution	$112 \times 112$			$7 \times 7$ conv, stride 2	
Pooling	$56 \times 56$			$3 \times 3$ max pool, stride 2	
Dense Block (1)	$56 \times 56$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 6$
Transition Layer (1)	$56 \times 56$			$1 \times 1$ conv	
	$28 \times 28$			$2 \times 2$ average pool, stride 2	
Dense Block (2)	$28 \times 28$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 12$
Transition Layer (2)	$28 \times 28$			$1 \times 1$ conv	
	$14 \times 14$			$2 \times 2$ average pool, stride 2	
Dense Block (3)	$14 \times 14$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 48$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 36$
Transition Layer (3)	$14 \times 14$			$1 \times 1$ conv	
	$7 \times 7$			$2 \times 2$ average pool, stride 2	
Dense Block (4)	$7 \times 7$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 16$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 32$	$\begin{bmatrix} 1 \times 1 \text{ conv} \\ 3 \times 3 \text{ conv} \end{bmatrix} \times 24$
Classification Layer	$1 \times 1$			$7 \times 7$ global average pool	
				1000D fully-connected, softmax	

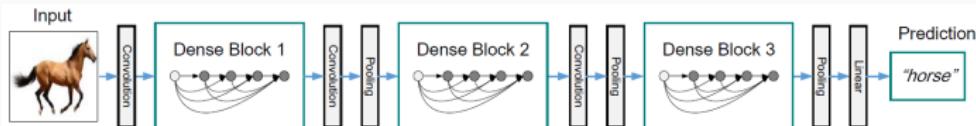


Imagen y tabla tomadas de Huang et al. Densely Connected Convolutional Networks, 2018

## Filtros separables

- Filtros que pueden descomponerse como el producto de 2 más simples. Por ej., un filtro 2D puede separarse en 2 filtros 1D.

$$\begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} \times \begin{bmatrix} -1 & 0 & 1 \end{bmatrix}$$

# Convolución espacial separable

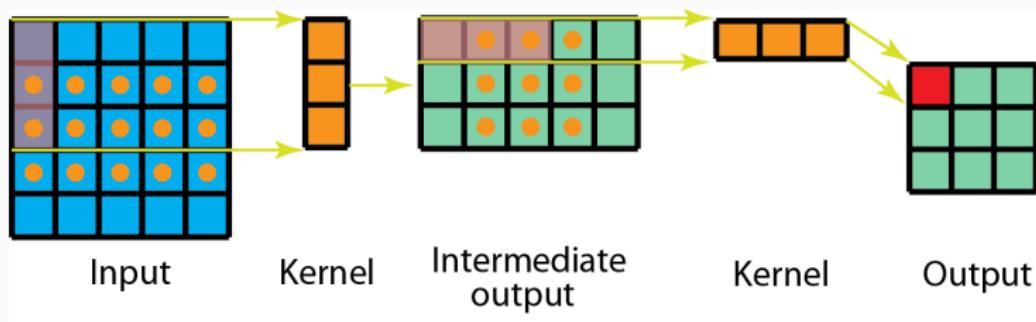


Imagen tomada de Kunlun Bai. A Comprehensive Introduction to Different Types of Convolutions in Deep Learning, 2019.

# Convolución en profundidad

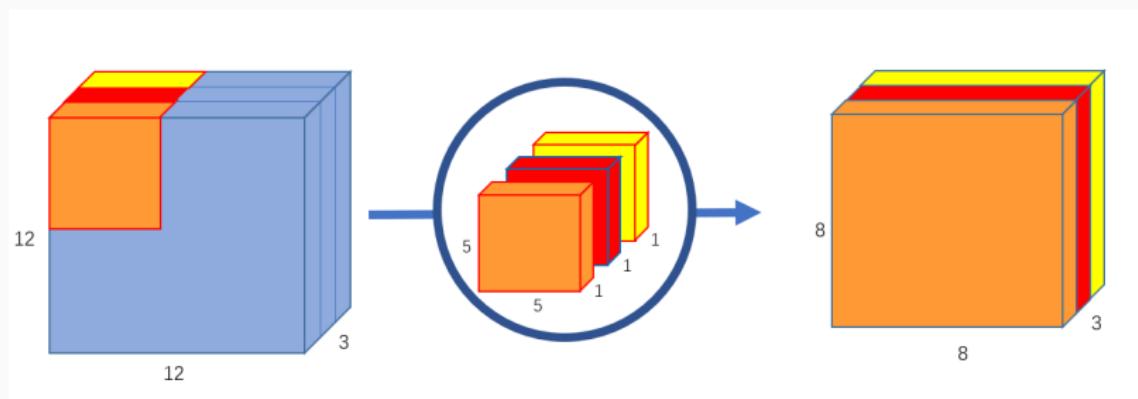


Imagen tomada de Chi-Feng Wang, A Basic Introduction to Separable Convolutions, 2018.

# Convolución puntual (de $1 \times 1$ )

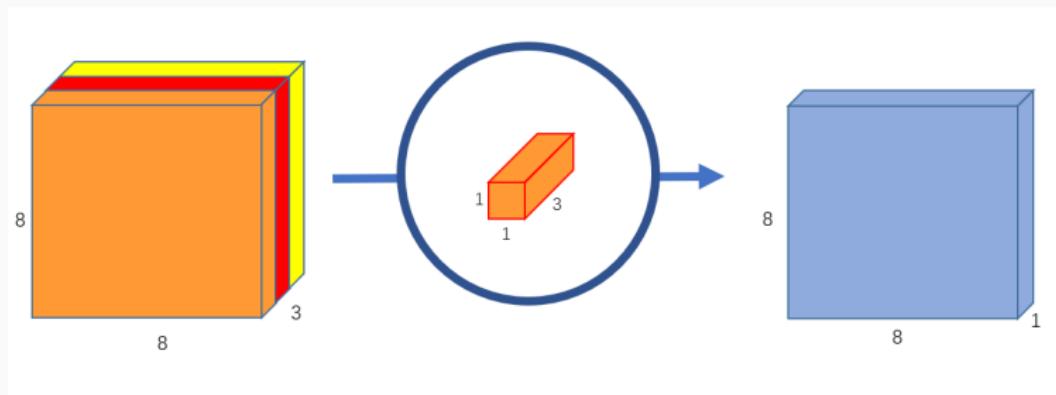


Imagen tomada de Chi-Feng Wang, A Basic Introduction to Separable Convolutions, 2018.

# Convolución puntual (de $1 \times 1$ )

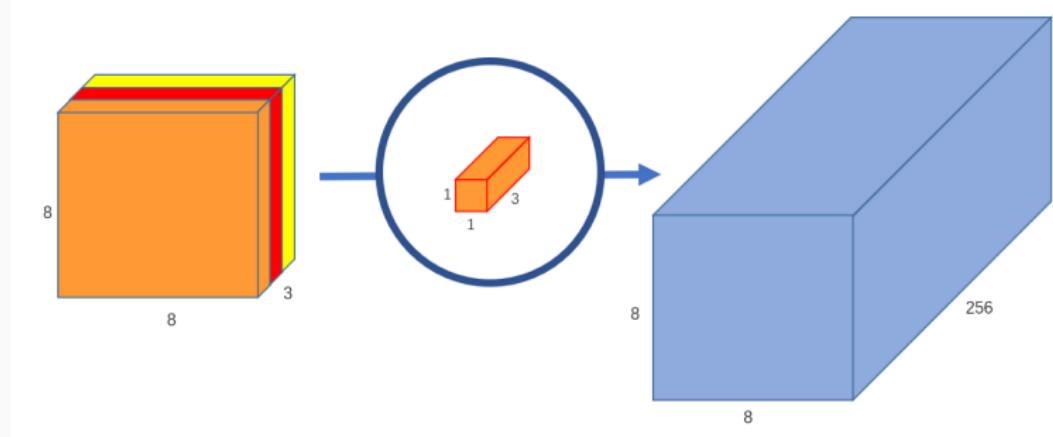


Imagen tomada de Chi-Feng Wang. A Basic Introduction to Separable Convolutions, 2018.

# Convolución separable en profundidad

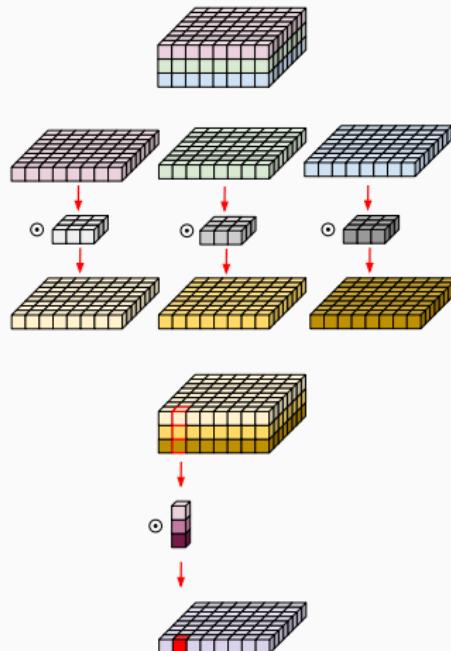


Imagen tomada de Eli Bendersky. Depthwise separable convolutions for machine learning, 2018.

# Bloques Inception y convoluciones separables

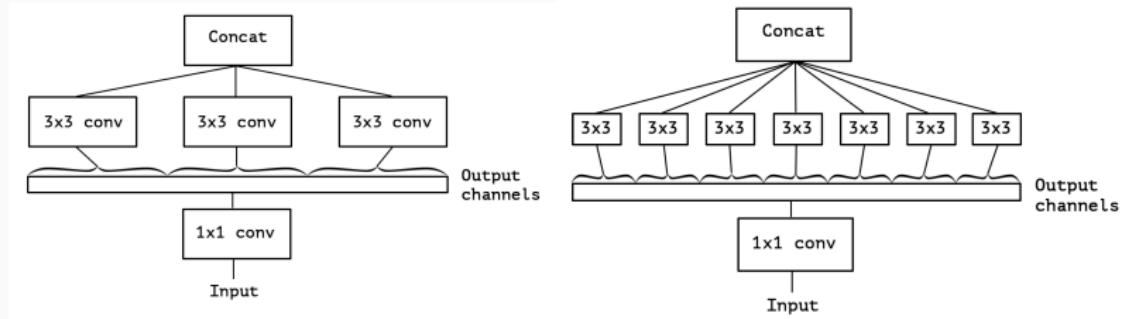


Imagen tomada de F. Chollet. Xception: Deep Learning with Depthwise Separable Convolutions, 2017.

# Xception

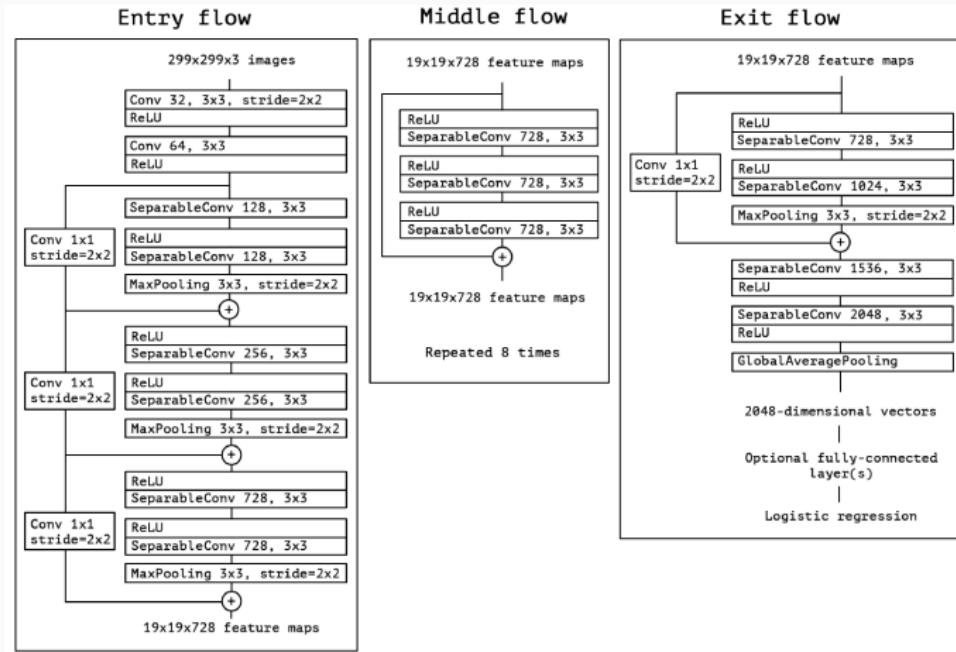


Imagen tomada de F. Chollet. Xception: Deep Learning with Depthwise Separable Convolutions, 2017.

# Convolución dilatada

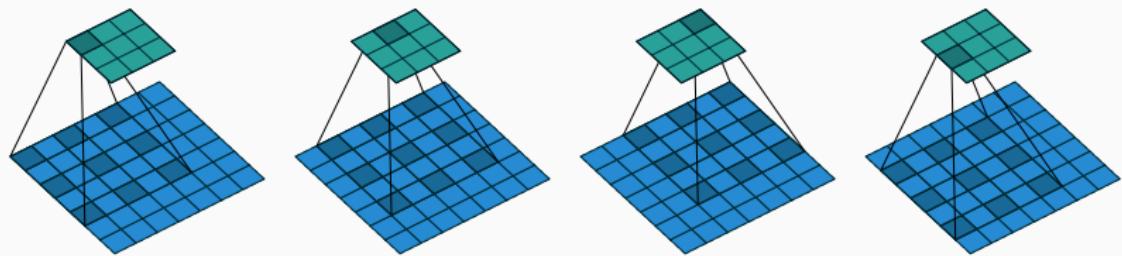


Imagen tomada de Dumoulin and Visin. *A guide to convolution arithmetic for deep learning*, 2018.

# Visualizando respuestas

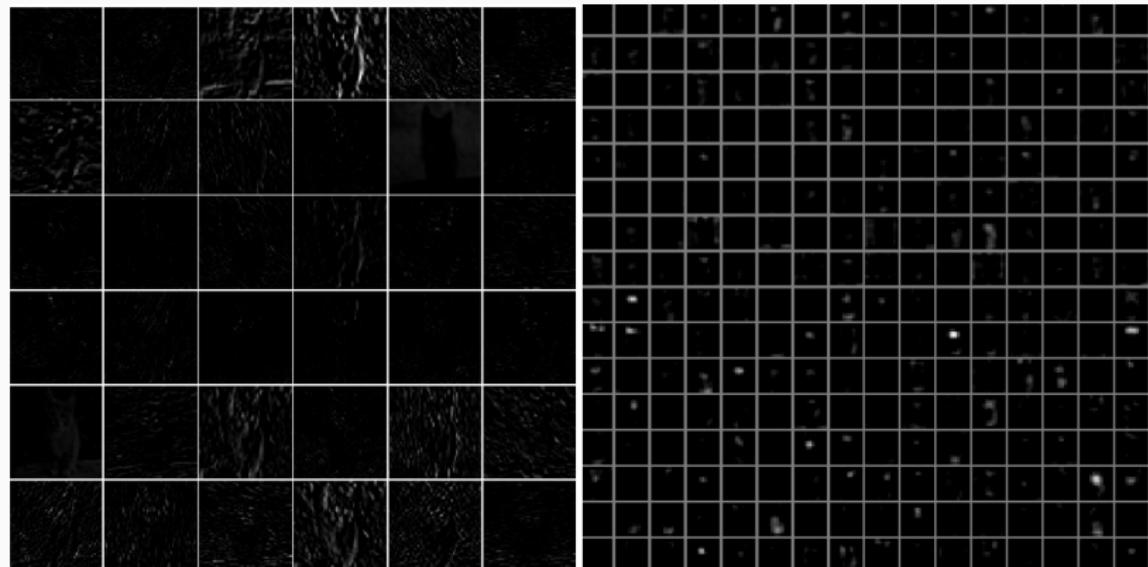


Imagen tomada de <http://cs231n.github.io/understanding-cnn/>

# Visualizando pesos

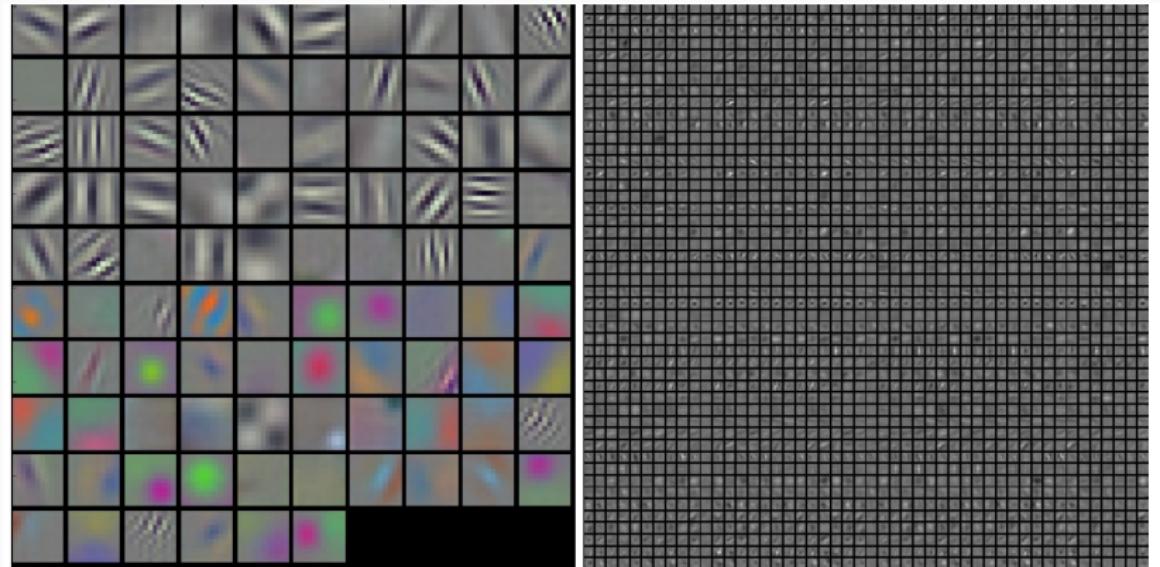


Imagen tomada de <http://cs231n.github.io/understanding-cnn/>

# Visualizando imágenes con respuestas máximas



Imagen tomada de <http://cs231n.github.io/understanding-cnn/>

# Visualizando obstrucciones

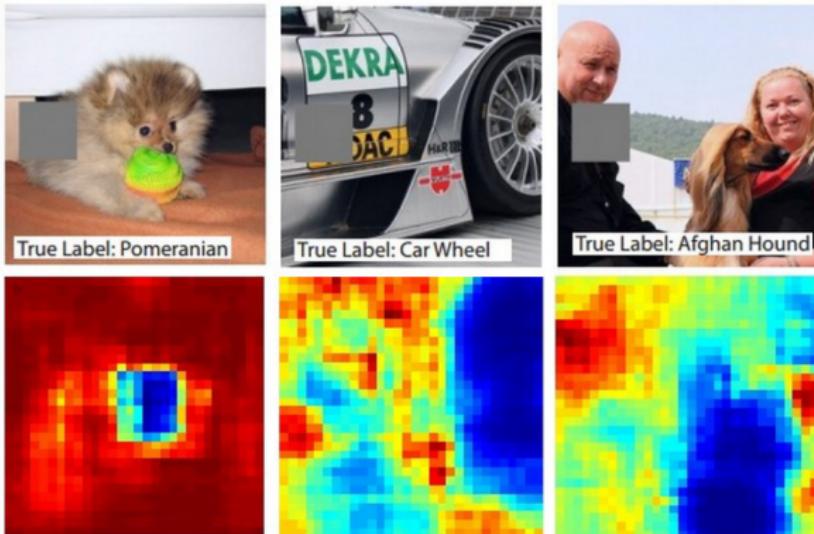


Imagen tomada de <http://cs231n.github.io/understanding-cnn/>

# Red de-deconvolucional

- Se puede poner una red de-deconvolucional en cada capa de una red convolucional para visualizar sus respuestas

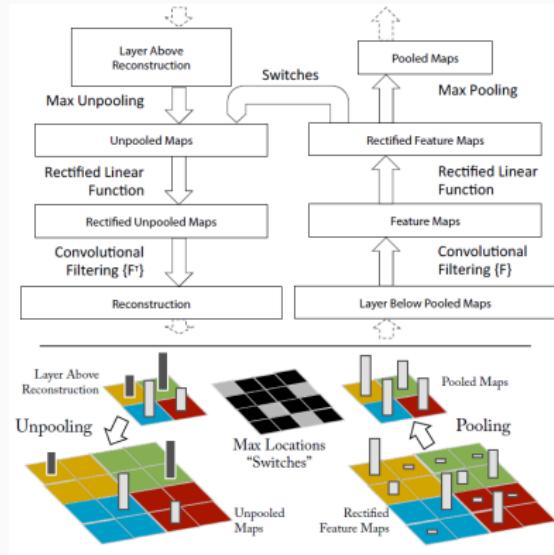


Imagen tomada de Zeiler and Fergus. *Visualizing and Understanding Convolutional Networks*, 2014

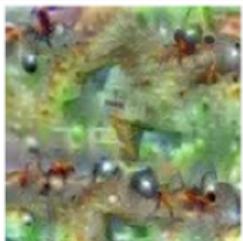
# DeepDream de Google: diferentes clases



Hartebeest



Measuring Cup



Ant



Starfish



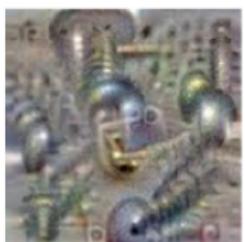
Anemone Fish



Banana



Parachute



Screw

Imagen tomada de <https://research.googleblog.com/2015/06/inceptionism-going-deeper-into-neural.html>

# DeepDream de Google: características de bajo nivel

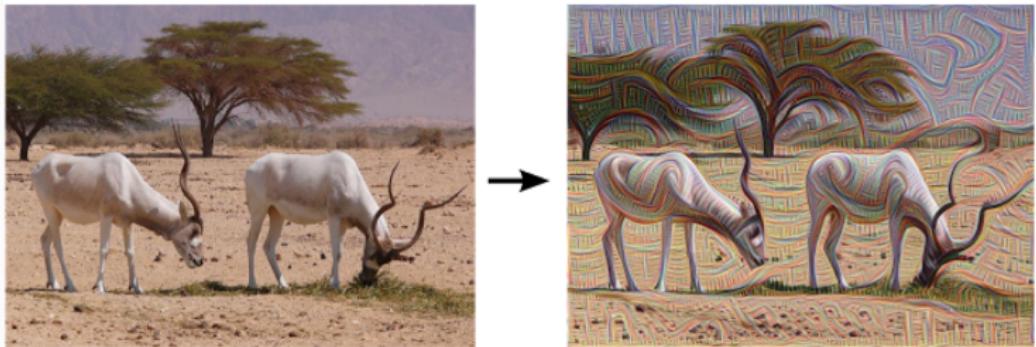


Imagen tomada de <https://research.googleblog.com/2015/06/inceptionism-going-deeper-into-neural.html>

# DeepDream de Google: características de alto nivel



"Admiral Dog!"



"The Pig-Snail"



"The Camel-Bird"



"The Dog-Fish"

Imagen tomada de <https://research.googleblog.com/2015/06/inceptionism-going-deeper-into-neural.html>

# DeepDream de Google: influencia de imagen original

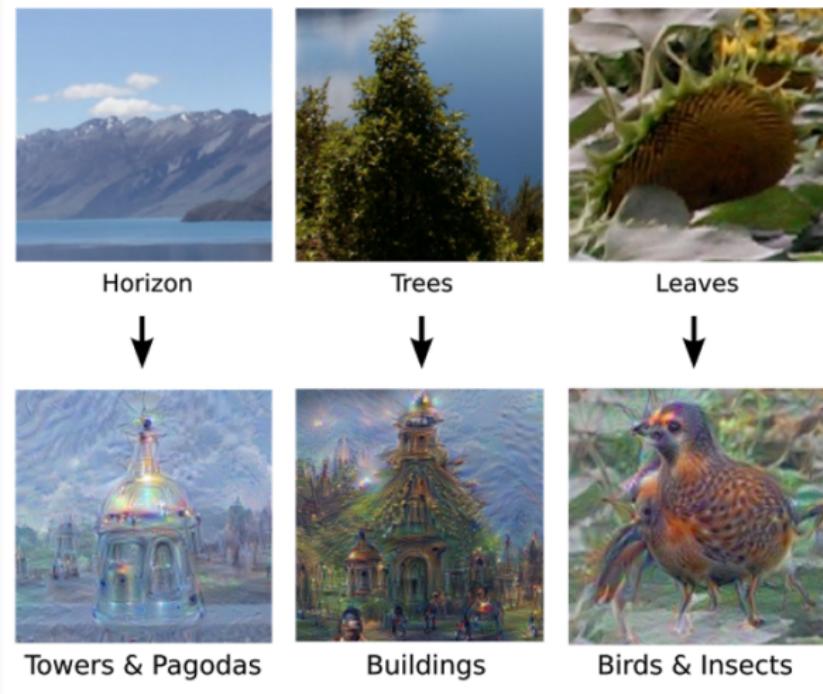


Imagen tomada de <https://research.googleblog.com/2015/06/inceptionism-going-deeper-into-neural.html>

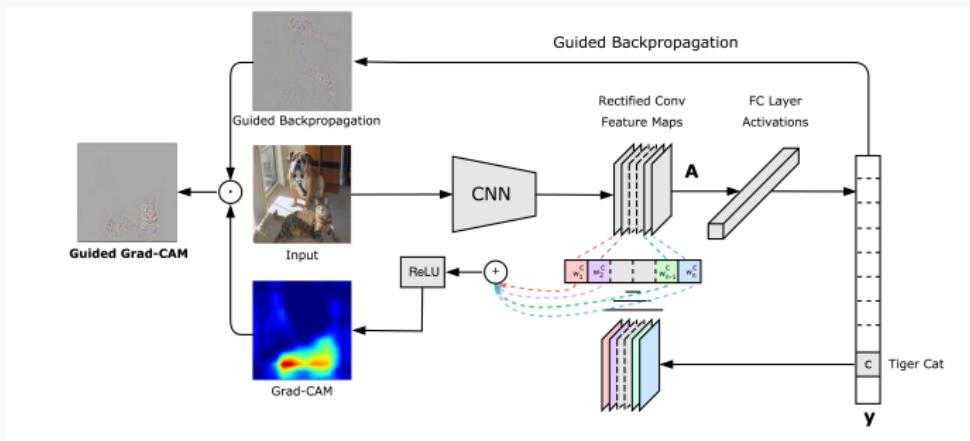
# DeepDream de Google: de forma aleatoria e iterativa



Imagen tomada de <https://research.googleblog.com/2015/06/inceptionism-going-deeper-into-neural.html>

# Gradient-weighted Class Activation Mapping (Grad-CAM)

- Método para visualizar las regiones de la imagen que el modelo considera más importantes para una predicción
- Emplea información de los gradientes específicos a la clase para producir un mapa de calor de importancia



# Redes convolucionales 1D

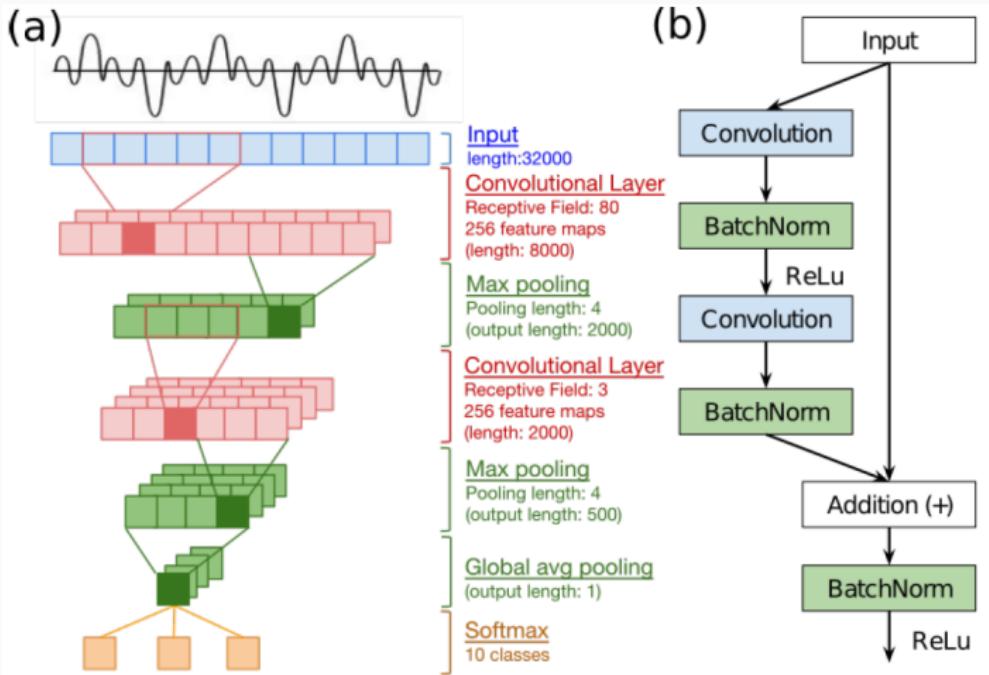


Imagen tomada de Dai et al. *Very Deep Convolutional Neural Networks for Raw Waveforms*, 2016

# Redes convolucionales 3D (1)

- Respuesta en redes convolucionales 2D en una imagen

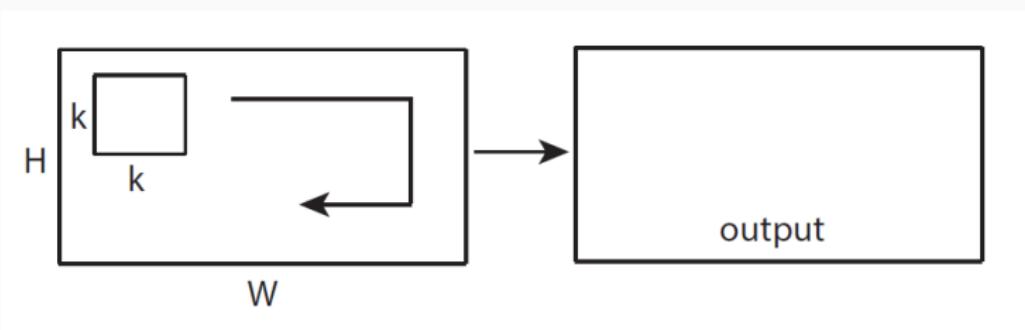


Imagen tomada de Tran et al. *Learning Spatiotemporal Features with 3D Convolutional Networks*, 2015

## Redes convolucionales 3D (2)

- Respuesta en redes convolucionales 2D en varias imágenes

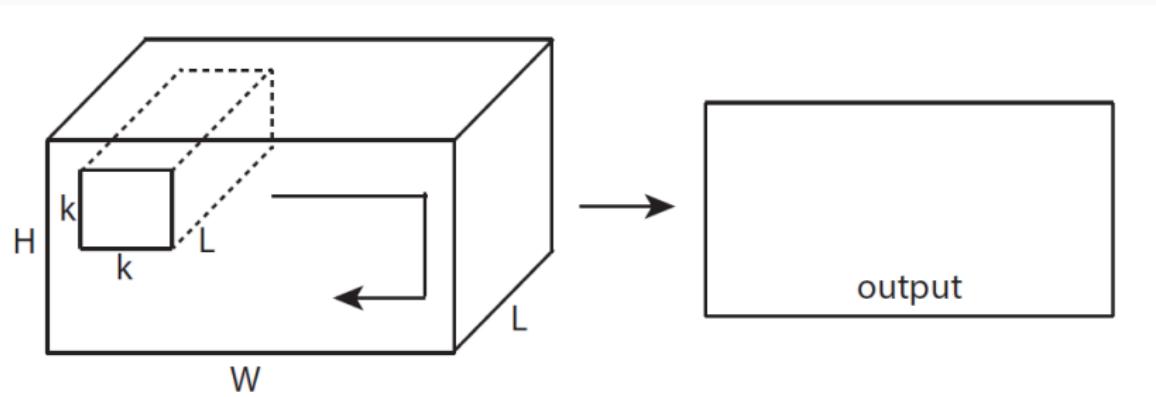


Imagen tomada de Tran et al. *Learning Spatiotemporal Features with 3D Convolutional Networks*, 2015

## Redes convolucionales 3D (3)

- Respuesta en redes convolucionales 3D

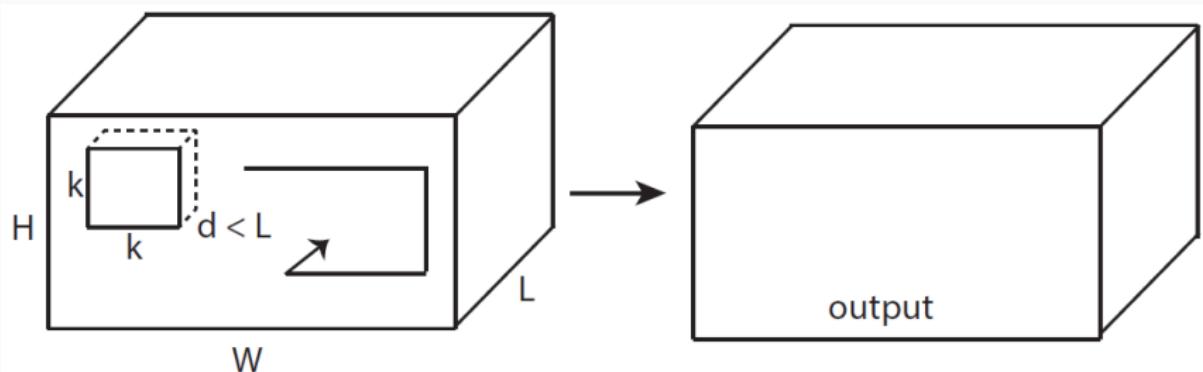


Imagen tomada de Tran et al. *Learning Spatiotemporal Features with 3D Convolutional Networks*, 2015

# Aprendizaje por transferencia

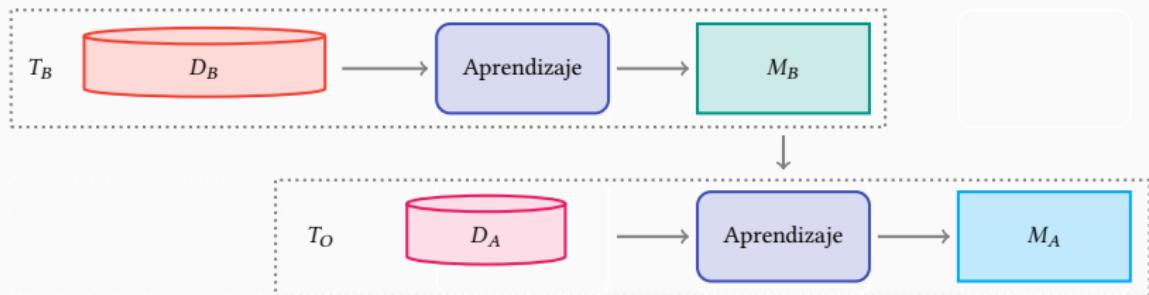


Imagen cortesía de Berenice Montalvo

# Desempeño en distintas tareas

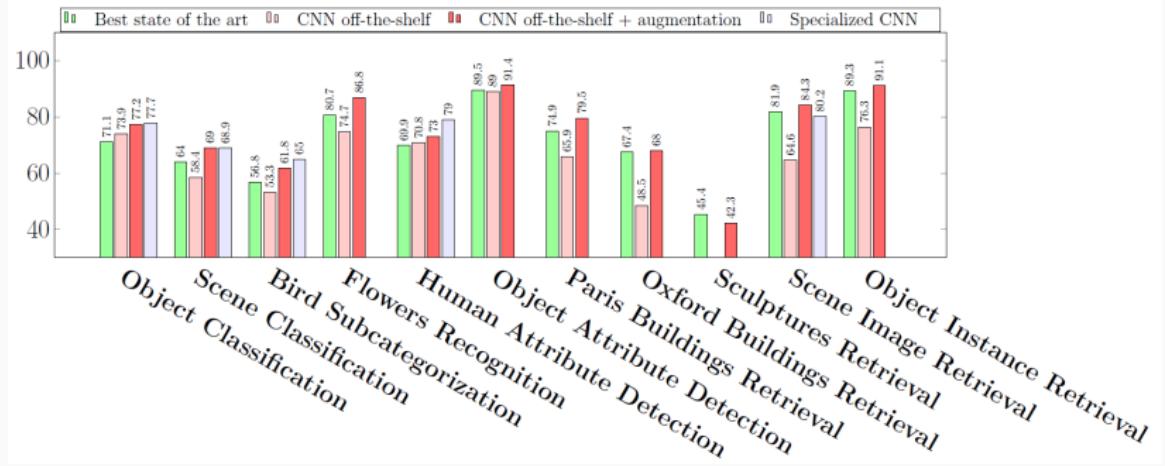


Imagen tomada de Razavian et al. CNN Features off-the-shelf: an Astounding Baseline for Recognition, 2014

# Desempeño en tareas con distintas características (1)

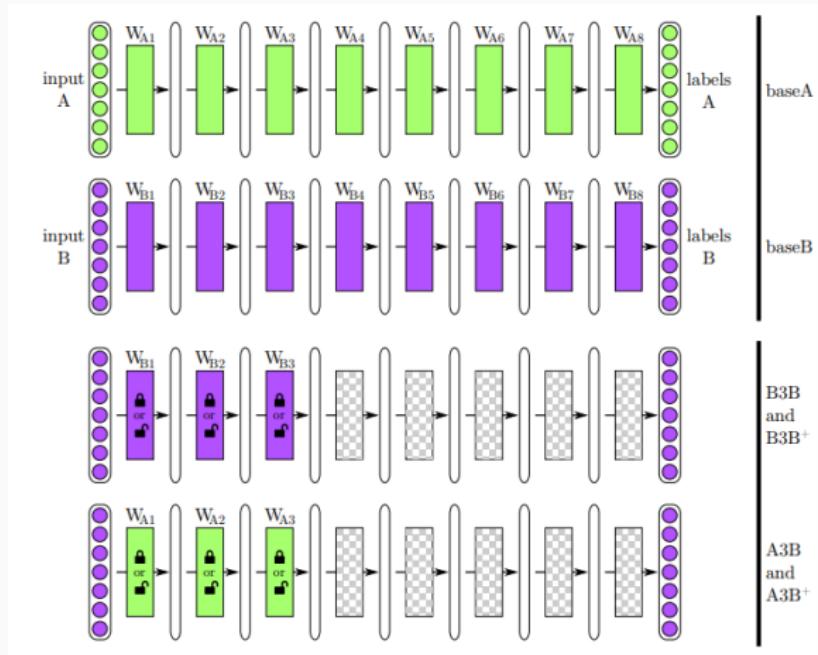


Imagen tomada de Yosinski et al. How transferable are features in deep neural networks?, 2014

# Desempeño en tareas con distintas características (2)

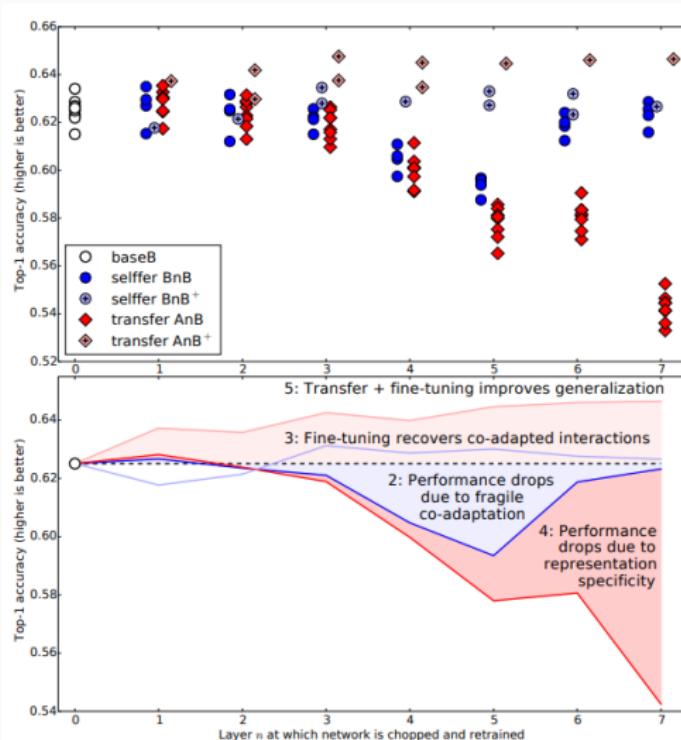


Imagen tomada de Yosinski et al. How transferable are features in deep neural networks?, 2014